



UNSTA

# PROYECTO DE INVESTIGACIÓN

**BOOTSTRAP Y SUS APLICACIONES  
EN INGENIERÍA EN IA**

## CARRERA:

Ingeniería en Inteligencia Artificial

## ASIGNATURA:


Probabilidad y Estadística - 2do año

## DOCENTES A CARGO:

MSc. M. Isabel Giannini - Lic. M. Florencia Mignone

## INTEGRANTES:

Barrios, Julieta Luján - Chalín Matías Alejandro - Granito,  
Leandro Elio - Sappia, Lucio Agustín



# ÍNDICE

|                                                            |           |
|------------------------------------------------------------|-----------|
| <b>1. INTRODUCCIÓN</b>                                     | <b>1</b>  |
| <b>2. EXPLORACIÓN Y PREPROCESAMIENTO DE DATOS</b>          | <b>1</b>  |
| 2.1. Análisis Exploratorio de Variables                    | 2         |
| 2.2. Limpieza e Imputación de Datos                        | 3         |
| 2.3. Codificación y Selección de Características           | 3         |
| <b>3. IMPLEMENTACIÓN DE ESTIMADORES INICIALES</b>          | <b>4</b>  |
| 3.1. Construcción del Modelo Base                          | 5         |
| <b>4. APLICACIÓN Y ANÁLISIS DEL MÉTODO BOOTSTRAP</b>       | <b>6</b>  |
| <b>5. DISCUSIÓN: INTEGRACIÓN Y VARIABILIDAD DEL MODELO</b> | <b>8</b>  |
| <b>6. CONCLUSIONES Y OBSERVACIONES EMPÍRICAS</b>           | <b>9</b>  |
| <b>7. BIBLIOGRAFÍA Y FUENTES</b>                           | <b>11</b> |

## 1. INTRODUCCIÓN

El método de **Bootstrap** (o *bootstrapping*) se define como una técnica de remuestreo estadístico que fundamenta su operativa en el muestreo repetido de un único conjunto de datos empírico. Su finalidad es generar múltiples muestras simuladas que permitan aproximar la distribución muestral de un estimador y calcular medidas críticas como la variabilidad, el sesgo y los intervalos de confianza.

En el contexto de la investigación estadística rigurosa, frecuentemente resulta inviable recopilar datos de la totalidad de una población, debido a limitaciones presupuestarias, temporales o logísticas. La práctica estándar consiste en seleccionar una muestra representativa para inferir las propiedades del conjunto global. El *bootstrapping* maximiza la utilidad de esta muestra: permite obtener información de alta precisión de manera ágil y económica, simulando miles de escenarios posibles a partir de los datos disponibles.

Al calcular una estadística de interés, este remuestreo permite generar miles de réplicas, cada una arrojando su propia estimación. Esto facilita a los equipos de investigación para construir **Intervalos de Confianza (IC)** más precisos y robustos, superando las limitaciones de basarse en una única estimación puntual. Cabe definir que un intervalo de confianza es el rango de valores dentro de una distribución muestral en el cual, con un determinado nivel de probabilidad (nivel de confianza), se estima que reside el verdadero valor del parámetro poblacional (como la media).

Para la aplicación práctica de esta metodología, se utilizó el conjunto de datos 'train.csv' perteneciente a la base de datos "*Titanic - Machine Learning from Disaster*" de la plataforma Kaggle. Este dataset contiene registros demográficos y logísticos de los pasajeros del Titanic, siendo la variable crítica el **estado de supervivencia**.

El objetivo central del proyecto es abordar un problema de **clasificación binaria**: desarrollar un modelo predictivo capaz de determinar si un pasajero sobrevivió o no, basándose en sus características. La estrategia metodológica es amplia y consiste en aplicar el método Bootstrap tanto para obtener estimaciones robustas de estadísticos descriptivos y correlaciones, como para la evaluación de un modelo de Inteligencia Artificial —en este caso particular una **Regresión Logística**—, utilizando la exactitud (Accuracy) como métrica principal para evaluar no solo el rendimiento, sino la estabilidad del modelo.

## 2. EXPLORACIÓN Y PREPROCESAMIENTO DE DATOS

Para el desarrollo técnico del proyecto se utilizó el entorno [\*\*Google Colab\*\*](#), facilitando la escritura de código colaborativa y la visualización de cambios en tiempo real. El flujo de trabajo inició con la importación del dataset desde Google Drive y la carga de librerías esenciales para el análisis de datos y aprendizaje automático, predominantemente del ecosistema *Scikit-Learn*.

## 2.1. Análisis Exploratorio de Variables

En una primera instancia, se realizó una exploración exhaustiva para comprender la estructura del dataset y determinar las necesidades de limpieza. El conjunto de datos consta de 891 registros (pasajeros) y 12 variables o campos informativos:

- **PassengerId**: Identificador único y secuencial por pasajero.
- **Survived**: Variable objetivo (binaria); toma valor 0 (no sobrevivió) o 1 (sobrevivió).
- **Pclass**: Clase socioeconómica del ticket (1, 2 o 3).
- **Name**: Nombre completo del pasajero.
- **Sex**: Género del pasajero (male o female).
- **Age**: Edad en años.
- **SibSp**: Número de hermanos o cónyuges a bordo.
- **Parch**: Número de padres o hijos a bordo.
- **Ticket**: Número de serie del ticket.
- **Fare**: Tarifa pagada por el pasajero.
- **Cabin**: Número de cabina asignada.
- **Embarked**: Puerto de embarque (C = Cherburgo, Q = Queenstown, S = Southampton).

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
#   Column             Non-Null Count  Dtype  
---  --
0   PassengerId        891 non-null    int64  
1   Survived           891 non-null    int64  
2   Pclass             891 non-null    int64  
3   Name               891 non-null    object  
4   Sex                891 non-null    object  
5   Age               714 non-null    float64 
6   SibSp             891 non-null    int64  
7   Parch             891 non-null    int64  
8   Ticket            891 non-null    object  
9   Fare              891 non-null    float64 
10  Cabin             204 non-null    object  
11  Embarked          889 non-null    object
```

Es fundamental aclarar que no todas las variables quedarán para el ajuste final del modelo. Se realizará un proceso de selección de características para discernir cuáles realmente aportan información significativa para explicar la variable "Survived", descartando aquellas que no influyen en la predicción. Las variables que sí quedan seleccionadas están detalladas más adelante, en la sección 2.3, como **variables predictoras (X)**.

Asimismo, se analizó la distribución de la variable objetivo **Survived**. Desde un punto de vista estadístico, esta variable se puede modelar mediante una distribución de *Bernoulli*, dado su comportamiento binario. Sin embargo, su parámetro  $p$  (probabilidad real de supervivencia) es desconocido debido a que la cantidad de pasajeros en el dataset no corresponde a la totalidad de la población histórica. En consecuencia, se ha estimado el valor de dicha probabilidad utilizando la proporción muestral, la cual constituye el *Estimador de Máxima Verosimilitud* (MLE) para este parámetro.

El análisis revela un desbalance de clases: aproximadamente un **62% de no-sobrevivientes** frente a un **38% de sobrevivientes**.

```
df['Survived'].value_counts(normalize=True)
```

| proportion |          |
|------------|----------|
| Survived   |          |
| 0          | 0.616162 |
| 1          | 0.383838 |

## 2.2. Limpieza e Imputación de Datos

Tras el análisis estructural, se procedió a la detección de valores ausentes (nulos). Se identificaron faltantes en las variables: Age (177 valores), Cabin (687 valores) y Embarked (2 valores). La estrategia de manejo de datos fue la siguiente:

- **Age:** Se imputaron los valores faltantes utilizando la **mediana** de la columna. Se optó por la mediana en lugar de la media para preservar la distribución central de los datos numéricos y minimizar el impacto de valores atípicos.
- **Embarked:** Se imputaron los nulos con la **moda** (el valor más frecuente), criterio estándar para variables categóricas.
- **Cabin:** Se decidió excluir esta columna del entrenamiento debido a la excesiva cantidad de datos faltantes (>77%), lo cual impide que aporte información relevante para la predicción.

```
df.isna().sum()
```

|             |     |
|-------------|-----|
|             | 0   |
| PassengerId | 0   |
| Survived    | 0   |
| Pclass      | 0   |
| Name        | 0   |
| Sex         | 0   |
| Age         | 177 |
| SibSp       | 0   |
| Parch       | 0   |
| Ticket      | 0   |
| Fare        | 0   |
| Cabin       | 687 |
| Embarked    | 2   |

## 2.3. Codificación y Selección de Características

Para que el modelo matemático pueda procesar la información, fue necesario codificar las variables categóricas:

- **Sex:** Al tratarse de una variable categórica, se codificaron sus etiquetas ("*male*", "*female*") asignándoles valores binarios (0 y 1) mediante funciones de mapeo (.map). Es importante notar que, aunque se represente con números, la variable sigue siendo conceptualmente categórica nominal.
- **Embarked:** Al ser una variable categórica nominal sin orden intrínseco, se aplicó la técnica de *OneHotEncoder*.

Posteriormente, se definieron las variables predictoras (**X**) y la variable objetivo (**Y**) (*Survived*). Se seleccionaron como relevantes para **X**: Pclass, Sex, Age, SibSp, Parch, Fare y Embarked. Se excluyeron PassengerId, Name y Ticket por no aportar valor predictivo generalizable.

Finalmente, se implementó un preprocesador utilizando 'ColumnTransformer' para aplicar estandarización (*StandardScaler*) a las variables numéricas y codificación a las categóricas, asegurando que todas las variables operen en escalas comparables.



### 3. IMPLEMENTACIÓN DE ESTIMADORES INICIALES

Previo a la implementación del modelo de Inteligencia Artificial, se realizó un análisis estadístico específico para validar la relevancia de las variables seleccionadas y descartar redundancia de información entre ellas.

#### Estimador 1: *Diferencia de Tarifas*


Se analizó la distribución de la variable *Fare* condicionada por la variable *Survived*. Visualizar los valores de tarifa agrupados por supervivencia sugiere una discrepancia notable, lo que justifica estudiar formalmente la diferencia de medias. Se calculó la diferencia en el promedio de la tarifa (*Fare*) entre los pasajeros que sobrevivieron y los que no.

- **Resultado:** 26.28.
- **Interpretación:** Este valor indica que, en promedio, los supervivientes pagaron \$26.28 unidades monetarias más que las víctimas, sugiriendo una correlación positiva entre el poder adquisitivo y la supervivencia. Esta diferencia significativa reafirma que *Fare* es una variable de interés crítica para la regresión, ya que discrimina bien entre las clases.

#### Estimador 2: *Correlación de Pearson (Edad vs. Tarifa)*

Se calculó el coeficiente de correlación de Pearson entre *Age* y *Fare*. Esta prueba estadística mide la fuerza y dirección de la relación lineal entre dos variables continuas, oscilando entre +1 (correlación positiva perfecta) y -1 (correlación negativa perfecta), donde 0 implica ausencia de linealidad.

- **Resultado:** 0.10.
- **Interpretación:** El valor obtenido indica una asociación positiva pero extremadamente débil. Aunque existe una ligera tendencia a que mayor edad implique mayor tarifa, la relación no es determinante. El valor de este resultado radica en que ambas variables aportan **dimensiones diferentes al** ajuste de la regresión. La falta de correlación lineal fuerte es favorable, pues sugiere ausencia de multicolinealidad: la *Age* aporta información que la *Fare* no contiene, y viceversa.



Los puntos no se agrupan significativamente en una dirección ascendente o descendente. Aunque se pueden ver algunos puntos con tarifas muy altas que corresponden a un rango de edades medio-alto, la mayoría de los pasajeros se concentran en tarifas más bajas, independientemente de su edad. Esta distribución visual refuerza el bajo coeficiente de correlación obtenido (alrededor de 0.10), sugiriendo que 'Edad' y 'Tarifa' son variables mayormente independientes.

### 3.1. Construcción del Modelo Base

Una vez analizados los estimadores simples, se procedió a construir el modelo principal. Se dividió el dataset en conjuntos de entrenamiento (70%) y prueba (30%), resultando en 623 registros para entrenamiento y 268 para prueba, manteniendo la proporción de clases.

**Definición del Modelo:** Se planteó un modelo de **Regresión Logística**.

- **Variable Explicada (Y):** La probabilidad de que Survived sea igual a 1.
- **Variables Explicativas (X):** Pclass, Sex, Age, SibSp, Parch, Fare y Embarked.


Estas variables fueron seleccionadas tras el análisis exploratorio (Sección 2), descartando aquellas que no aportaban capacidad discriminante. Se construyó un *pipeline* integrando el preprocesador y el clasificador. Tras entrenar el modelo y evaluarlo en el conjunto de prueba, se calcularon dos métricas para medir su rendimiento:

- **Accuracy (Exactitud):** Mide la proporción total de predicciones correctas.
- **F1-Score:** Media armónica entre precisión y sensibilidad (*recall*), métrica más adecuada ante el desbalance de clases existente (más no-sobrevivientes que sobrevivientes).

**Métricas obtenidas:**

- **Accuracy:** 0.7985
- **F1-Score:** 0.7353

También se obtuvo una matriz de confusión y un reporte de clasificación completo para el modelo base.



La matriz de confusión del modelo con un Accuracy de aproximadamente 80% se obtuvo al aplicar el modelo ya entrenado exclusivamente sobre el conjunto de datos de **prueba** y comparar estas predicciones con la verdadera condición de los pasajeros respecto a la variable Survived.

Muestra que se predijo correctamente que 139 pasajeros no sobrevivieron, incorrectamente que 26 sobrevivieron cuando en realidad no lo hicieron (Error de Tipo I), incorrectamente que 28 no sobrevivieron cuando en realidad sí (Error de Tipo II), y correctamente que 75 pasajeros sobrevivieron.

```
print(classification_report(y_prueba, y_pred))
```

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0            | 0.83      | 0.84   | 0.84     | 165     |
| 1            | 0.74      | 0.73   | 0.74     | 103     |
| accuracy     |           |        | 0.80     | 268     |
| macro avg    | 0.79      | 0.79   | 0.79     | 268     |
| weighted avg | 0.80      | 0.80   | 0.80     | 268     |

Reporte de clasificación completo:

- **Precision:** Indica la calidad de las predicciones positivas. De todos los que el modelo etiquetó como "Sobrevivientes" (clase 1), el 74% realmente lo eran.
- **Recall:** Mide la capacidad del modelo para encontrar los casos positivos. De todos los que realmente sobrevivieron, el modelo detectó correctamente al 73%.
- **F1-Score:** Es la media armónica entre Precision y Recall. Funciona como una métrica única que balancea ambas cualidades.
- **Support:** Indica la cantidad real de ocurrencias de cada clase en el conjunto de prueba (165 fallecidos y 103 sobrevivientes).
- **Macro avg:** Calcula el promedio de las métricas para ambas clases sin considerar el desbalance (trata a ambas clases como igual de importantes).
- **Weighted avg:** Calcula el promedio ponderado según el soporte de cada clase. Al ser 0.80, confirma que el modelo se comporta de manera estable considerando la proporción real de pasajeros.


## 4. APLICACIÓN Y ANÁLISIS DEL MÉTODO BOOTSTRAP

### Estimador de Diferencia de Tarifas

Se observa la distribución de la diferencia de medias obtenida tras 1000 iteraciones. Para determinar el intervalo de confianza, se utilizó el **Método de Percentiles**. Dado que se buscó un nivel de confianza del 95% ( $1-\alpha=0.95$ ), se ordenaron las estimaciones de menor a mayor y se seleccionaron los valores correspondientes a los percentiles 2.5 y 97.5 (recortando el  $\alpha/2$  en cada extremo), sin asumir normalidad teórica en los datos.

- **Media Bootstrap:** 26.08.
- **Intervalo de Confianza (95%):** (19.03, 33.75).
- **Análisis:** El intervalo es consistentemente positivo y no incluye el cero. Esto confirma estadísticamente que los supervivientes pagaron significativamente más. La media bootstrap (26.08) es muy cercana al estimador original (26.28), indicando consistencia.






### **Estimador de Correlación (Edad - Tarifa)**

Aplicando la misma metodología de percentiles para construir el intervalo sobre las remuestras del coeficiente de correlación de Pearson:

- **Media Bootstrap:** 0.0968.
- **Intervalo de Confianza (95%):** (0.0444, 0.1556).
- **Análisis:** El intervalo confirma una correlación débil pero existente (siempre positiva). El hecho de que el límite inferior sea 0.0444 refuerza que, aunque la relación es tenue, no es aleatoria. Este resultado valida la robustez del cálculo original (0.10).




### Estimador basado en Accuracy (Modelo IA)

Este es el punto crítico de integración con la IA. Se generaron 1000 remuestras del conjunto de entrenamiento, reentrenando el modelo de Regresión Logística en cada iteración y evaluándolo en el conjunto de prueba fijo.

La construcción del Intervalo de Confianza se realizó nuevamente mediante el **Método de Percentiles**, identificando los límites que encierran el 95% central de las exactitudes obtenidas en las simulaciones.

- **Media Bootstrap:** 0.7963.
- **Intervalo de Confianza (95%):** (0.7799, 0.8098).
- **Análisis:** La distribución del accuracy es estrecha, concentrándose entre 0.79 y 0.81. La media bootstrap (0.7963) es prácticamente idéntica al accuracy del modelo base (0.7985), lo que sugiere que el modelo original no presentaba sesgos anómalos por la partición de datos específica.



El eje horizontal despliega el rango de variabilidad de la métrica obtenida a través de las distintas iteraciones del método Bootstrap. El eje vertical cuantifica el número de veces que el modelo alcanzó cada nivel específico de exactitud durante el proceso de remuestreo.

## 5. DISCUSIÓN: INTEGRACIÓN Y VARIABILIDAD DEL MODELO

La aplicación del Bootstrap al Accuracy del modelo permite trascender la evaluación puntual y comprender la fiabilidad del sistema. El Intervalo de Confianza del 95% obtenido (**0.7799, 0.8098**) es fundamental para la validación del despliegue.

Al analizar la amplitud de este intervalo, observamos un rango de aproximadamente **0.03 (3 puntos porcentuales)**.

- **Estabilidad:** Un rango tan estrecho indica que el modelo es altamente estable. Su rendimiento no varía drásticamente ante pequeñas perturbaciones o cambios en los datos de entrenamiento, lo cual es un indicador de robustez y ausencia de sobreajuste (*overfitting*) severo.
- **Confianza en la Estimación:** Podemos afirmar con un 95% de seguridad que el rendimiento real del modelo oscilará dentro de este rango. La baja dispersión refuerza la confianza en que el modelo se comportará de manera predecible con nuevos datos.

| ESTIMADOR DE INTERÉS          | Media Bootstrap | IC del 95%       | Interpretación Estadística                                                                                                                                                 |
|-------------------------------|-----------------|------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Diferencia de Tarifas         | 26.08           | (19.03, 33.75)   | El IC no incluye el 0 y es consistentemente positivo. Se confirma con un 95% de confianza que existe una diferencia significativa de precio a favor de los supervivientes. |
| Correlación (Edad vs. Tarifa) | 0.0968          | (0.0444, 0.1556) | El IC confirma una correlación positiva pero marginal. Aunque estadísticamente distinta de cero, la magnitud es despreciable para efectos predictivos fuertes.             |
| Accuracy del Modelo           | 0.7963          | (0.7799, 0.8098) | La media del bootstrap converge con la del modelo base, validando la representatividad del entrenamiento original.                                                         |

Tabla comparatoria de resultados al aplicar Bootstrap a cada estimador.

## 6. CONCLUSIONES Y OBSERVACIONES EMPÍRICAS

El desarrollo de este proyecto permitió profundizar en la construcción de estimadores, el método de percentiles para intervalos de confianza y en la comprensión práctica del *Teorema Central del Límite*. Esta comprensión se materializó al observar que, a pesar de que las variables originales del dataset (como Fare) no necesariamente siguen una distribución normal, las distribuciones de los estimadores generados mediante Bootstrap (medias muestrales, coeficientes) tendieron a adoptar una forma de campana (Gaussiana). Esta convergencia empírica valida visualmente que, con un número suficiente de remuestreos, la distribución muestral del estimador se aproxima a la normalidad, tal como predice la teoría.

Durante la ejecución surgieron interrogantes relevantes sobre la representatividad

de los datos. Al investigar la demografía histórica, se constató que el Titanic transportaba aproximadamente 2.220 personas. Nuestro dataset de 891 registros representa, por tanto, un 40% de la población real. Estadísticamente, esta es una muestra sumamente significativa, ideal para validar el rendimiento del Bootstrap.

Asimismo, destaca la eficiencia computacional observada: a pesar de configurar 1000 iteraciones de reentrenamiento, el proceso se ejecutó en menos de un minuto. Es importante aclarar que este rendimiento se debe a la combinación de dos factores: el uso de infraestructura en la nube optimizada (*Google Colab*) y el tamaño moderado de la muestra ( $n=891$ ). El Bootstrap es computacionalmente intensivo, y su tiempo de ejecución depende directamente del tamaño de los datos y la complejidad del modelo base.

A pesar de los resultados favorables (un intervalo de confianza con variación de apenas el 3%), es necesario reconocer las limitaciones inherentes al método:

- **Costo Computacional:** El método exige recursos significativos, ya que el tiempo de procesamiento escala linealmente con el número de remuestras ( $B$ ) y depende del tamaño de la muestra ( $n$ ). En contextos de *Big Data* o con modelos de entrenamiento lento (ej. Redes Neuronales Profundas), aplicar Bootstrap puede resultar inviable.
- **Dependencia Temporal/Espacial:** En su forma estándar, el método asume independencia entre observaciones, por lo que puede resultar incompatible o requerir adaptaciones complejas para series temporales o datos espaciales.
- **Riesgo de Sesgo:** Si la muestra original no es representativa, el Bootstrap amplificará ese sesgo en lugar de corregirlo.

Como conclusión final, el modelo de Regresión Logística demostró ser una solución robusta y fiable para el problema planteado, validada por una dispersión mínima en los intervalos de confianza generados.

Es posible acceder al desarrollo del proyecto a través del siguiente link:  
[https://colab.research.google.com/drive/103Z2sw-zsuKrgUUpjAuY4IT0Zo8xwyCs?  
usp=sharing](https://colab.research.google.com/drive/103Z2sw-zsuKrgUUpjAuY4IT0Zo8xwyCs?usp=sharing)

## 7. BIBLIOGRAFÍA Y FUENTES

Agarwal, R. (2023, 30 octubre). Confidence interval: explained. Built In. [https://builtin-com.translate.goog/data-science/confidence-intervals-explained?\\_x\\_tr\\_sl=en&\\_x\\_tr\\_tl=es&\\_x\\_tr\\_hl=es&\\_x\\_tr\\_pto=tc](https://builtin-com.translate.goog/data-science/confidence-intervals-explained?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc)

Chan, S. H. (2021). Introduction to Probability for Data Science. Michigan Publishing. Sección 9.2: Bootstrap.

Codificando Bits. (2025, 7 agosto). El BOOTSTRAPPING iexplicado! [Video]. YouTube. [https://www.youtube.com/watch?v=kK-YVhZD\\_PM](https://www.youtube.com/watch?v=kK-YVhZD_PM)

Efron, B. (1979). Bootstrap Methods: Another Look at the Jackknife. The Annals of Statistics, 7(1), 1-26.

Howell, D. C. (s. f.). Outline of StatPages. [https://www-uvm-edu.translate.goog/~statdhtx/StatPages/Randomization%20Tests/ResamplingWithR/BootstMeans/bootstraping\\_means.html?\\_x\\_tr\\_sl=en&\\_x\\_tr\\_tl=es&\\_x\\_tr\\_hl=es&\\_x\\_tr\\_pto=tc](https://www-uvm-edu.translate.goog/~statdhtx/StatPages/Randomization%20Tests/ResamplingWithR/BootstMeans/bootstraping_means.html?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc)

Joseph, T. (2025, 12 agosto). What is bootstrapping statistics? Built In. [https://builtin-com.translate.goog/data-science/bootstrapping-statistics?\\_x\\_tr\\_sl=en&\\_x\\_tr\\_tl=es&\\_x\\_tr\\_hl=es&\\_x\\_tr\\_pto=tc](https://builtin-com.translate.goog/data-science/bootstrapping-statistics?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc)

Mishra, M. L. (2023, 24 febrero). Central Limit Theorem (CLT) Definition and Examples. Built In. [https://builtin-com.translate.goog/data-science/understanding-central-limit-theorem?\\_x\\_tr\\_sl=en&\\_x\\_tr\\_tl=es&\\_x\\_tr\\_hl=es&\\_x\\_tr\\_pto=tc](https://builtin-com.translate.goog/data-science/understanding-central-limit-theorem?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc)

Ortega, C. (2023, 23 febrero). ¿Qué es el coeficiente de correlación de Pearson? QuestionPro. <https://www.questionpro.com/blog/es/coeficiente-de-correlacion-de-pearson/>

Titanic - Machine Learning from Disaster. (s. f.). Kaggle. <https://www.kaggle.com/competitions/titanic/data>